

Finanças Quantitativas: Lista 1

Lucas Machado Moschen

March 3, 2020

Problema 1.1

Assuma que $F_1(x)$ e $F_2(x)$ são cdfs que satisfazem $F_1(x) \leq F_2(x)$ para todo x .

1. Qual das duas distribuições tem cauda inferior mais pesada? Explique.

Resposta: Suponha que ambas as distribuições se estendem para $-\infty$. Se $X_i \sim F_i(x), i = 1, 2$, sabemos que $P[X_2 \leq \pi_p^{(2)}] = p = P[X_1 \leq \pi_p^{(1)}] \leq P[X_2 \leq \pi_p^{(1)}] \implies \pi_p^{(1)} \geq \pi_p^{(2)}$, onde $\pi_p^{(i)}$ é função quantil das distribuições $F_i(x), i = 1, 2$. Desta maneira, o quantil da primeira distribuição vai mais devagar para $-\infty$ e, portanto, a segunda curva tem cauda inferior mais pesada.

2. Qual das duas distribuições tem cauda superior mais pesada? Explique.

Resposta: Suponha que ambas as distribuições se estendem para ∞ . Pelo mesmo argumento utilizado na primeira pergunta, podemos observar que quando $p \rightarrow 1$, o quantil da primeira curva cresce mais rapidamente e, conseqüentemente, a primeira curva terá cauda superior mais pesada.

3. Se estas duas distribuições são propostas para modelar o retorno de um dado portfólio no próximo mês e se você é perguntado para computar $Var_{0.01}$ para este portfólio neste período, qual dessas duas distribuições resultaria o maior “value at risk”.

Resposta: Observe que se $P_{t+1}^i - P_t^i, i = 1, 2$ indica o retorno modelado pela distribuição 1 e 2, respectivamente. Assim

$$P[P_{t+1}^2 - P_t^2 < -VaR_p^2] = p = P[P_{t+1}^1 - P_t^1 < -VaR_p^1] \leq P[P_{t+1}^2 - P_t^2 < -VaR_p^1]$$

Desta forma, como já observamos, $-VaR_p^2 \leq -VaR_p^1 \implies VaR_p^2 \geq VaR_p^1$ e obtemos que se calcularmos VaR_p utilizando a segunda distribuição, ele terá um resultado maior.

Problema 1.2

1. Em R, gere uma $N = 1024$ amostras da distribuição exponencial com taxa $r = 0.2$. Chame X o vetor com as amostras. **Resposta:**

```
# Gerando variável aleatória X:  
U = runif(n = 1024, min = 0, max = 1)  
# Usamos a universalidade da Uniforme e a distribuição F da exponencial  
r = 0.2
```

```

F <- function(x, r){
  return <- 1 - exp(-r*x)
}
invF <- function(x,r){
  return <- -1/r*log(1 - x)
}
X = invF(U,r)
print(X[0:10])

```

```

## [1] 0.6374925 1.0299589 3.3463657 19.3593488 25.4603870 1.7264858
## [7] 7.0846877 0.4913075 9.2456724 6.2128635

```

2. Plote no mesmo gráfico a densidade exata de X e o histograma de X .

Resposta:

```


# Calculando o histograma
h <- hist(X, breaks = 30, col = 'red', main = 'Comparing sample and theoretical')

xfit <- seq(0, max(X), length= 50)
# Calculando a distribuição exponencial
yfit <- dexp(xfit, rate = 0.2 )
yfit <- yfit*diff(h$mids[1:2])*length(X)
lines(xfit, yfit, col="blue", lwd = 2)

legend(25, 100, legend=c("Sample", "Theoretical"),
      col=c("red", "blue"), lty=1:2, cex=0.8)

```

Comparing sample and theoretical




3. Plote no mesmo gráfico a densidade exata de X e uma estimativa da densidade kernel de X .

```
xfit <- seq(0, max(X),length= 40)

# A distribuição exponencial
yfit <- dexp(xfit,rate = 0.2)
# A estimacão da densidade kernel
yden <- density(X, bw = 0.5)
#Plotes
plot(yden$x, yden$y, col='red', xlim = c(1,max(X)), type = 'l', main = "Comparing Kernel Estimation and Theoretical",
     xlab = "X", ylab = "Density")
lines(xfit, yfit, col="blue", lwd = 2)

legend(20, 0.10, legend=c("Kernel Estimation", "Theoretical"),
      col=c("red", "blue"), lty=1:2, cex=0.8)
```

Comparing Kernel Estimation and Theoretical



4. Compare os dois plotes e explique as razões das diferenças. Diga qual estimativa você prefere, e explique porquê.

Resposta: Observe que tanto o histograma quanto a estimacão kernel da densidade se utilizam dos N dados. O histograma pode ser escrito em forma de uma função kernel, só que uma descontínua, já que tem um valor caso x , o valor da função, e x_i , uma amostra, estão no mesmo bin, e 0 caso não estejam. No caso da estimacão kernel, essa diferença é suave, bastando escolher uma função suave. Os saltos da aproximacão no caso do histograma é determinado pelo número de bins, enquanto no caso da estimacão kernel é o parâmetro “bandwidth”, logo podemos ter uma função tão suave quanto queremos. Desta maneira, é preferível essa estimacão kernel, pois suavizamos a função e podemos obter resultados mais precisos com a densidade almejada.

Problem 1.3

#again, we can input our R code here.